

Atelier 2 : MapReduce

Initiation :

Soit le fichier **sample.txt** qui contient les températures de plusieurs zones géographiques pour le mois de juillet 2007. On veut chercher la température maximale par jours.

1. Copier les deux scripts `mapper_maxT.py` et `reducer_maxT.py` dans le répertoire `/home/cloudera/cours`.
`cd /home/cloudera`
2. Donner le droit d'exécution des deux scripts
`sudo chmod +x cours/mapper_maxT.py cours/reducer_maxT.py`
3. Tester le mapper et reducer en local
`cat cours/sample.txt | cours/mapper_maxT.py | sort -k1,1 | cours/reducer_maxT.py`
4. Lancer un job entier sur Hadoop implique qu'on fera appel au mapper puis au reducer sur une entrée volumineuse, et obtenir à la fin un résultat, directement dans HDFS. Pour faire cela :
 - Créer un répertoire nommé 'myinput' sous HDFS `hadoop fs -mkdir myinput`
 - Copier le fichier `sample.txt` sous le répertoire `myinput` dans HDFS. `hadoop fs -put`
 - Exécuter l'instruction suivante :

```
hadoop jar /usr/lib/hadoop-0.20-mapreduce/contrib/streaming/hadoop-streaming-2.6.0-mr1-cdh5.12.0.jar \  
-file cours/mapper_maxT.py -mapper cours/mapper_maxT.py \  
-file cours/reducer_maxT.py -reducer cours/reducer_maxT.py \  
-input myinput/sample.txt -output joboutput
```

Joboutput est le répertoire de sortie, après exécution.

Remarque : Le répertoire de sortie ne doit pas exister avant l'exécution de l'instruction.